

# LightGCN

Jak mniej znaczy więcej w rekomendacjach grafowych?

# Problematyka

Klasyczne sieci neuronowe na grafach (NGCF) były **bardzo skomplikowane**.

**Sieci te miały mnóstwo skomplikowanych operacji takich jak**

- ◆ nieliniowości,
- ◆ transformacje cech,

które są potrzebne przy rozpoznawaniu obrazów, **ale odkryto, że...**


**Krytyczne pytanie**

**Czy transformacja cech i nieliniowa  
aktywacja są niezbędne w systemach  
rekomendacyjnych?**

# Zaskakujące odkrycie

Przeprowadzono badanie ablacyjne, w którym usunięto z NGCF transformację cech (-f), nieliniowość (-n) oraz obie operacje (-fn). Wyniki przeczą intuicji.


Skuteczność (Recall@20) na zbiorze Amazon-Book



Model **NGCF-fn** pozbawiony obu “ciężkich” operacji osiąga o **20,91% lepszy wynik Recall@20** na zbiorze Amazon-Book. Złożoność nie tylko nie pomaga, ale aktywnie szkodzi.

# Rozwiążanie – LightGCN

W oparciu o te odkrycia powstał LightGCN. Model ten porzuca zbędne operacje i skupia się na jednej kluczowej idei GCN dla rekomendacji: agregacji cech sąsiadów w celu “wygładzenia” embeddingów.



# **Implementacja**

# Środowisko uruchomieniowe

## 1. Platforma i Sprzęt:

- **Środowisko:** Google Colab (Cloud Jupyter Notebooks).
- **Akceleracja:** GPU NVIDIA Tesla T4 (wymagane dla efektywnego treningu GNN).
- **Język:** Python 3.x.

## 2. Stos Technologiczny:

- **Model LightGCN:** Własna implementacja „od zera” w **TensorFlow/Keras**.
- **Model NGCF:** Implementacja oparta na frameworku **RecBole** (backend **PyTorch**).

## 3. Gwarancja powtarzalności:

- **Determinizm:** Sztywne ustawienie ziarna losowości (**SEED = 2020**) dla bibliotek **numpy**, **random**, **tensorflow** i **torch**.
- **Spójność danych:** Zaimplementowano identyczny algorytm doboru próby (Sparse/Dense) w obu notatnikach, eliminując wpływ losowego doboru danych na wyniki porównania.

# Zbiór danych – Amazon-Book

## 1. Źródło i Charakterystyka:

- **Zbiór:** Amazon-Book.
- **Typ danych:** Implicit Feedback ([binarny](#)). Modelujemy sam fakt wystąpienia interakcji ([zakup/kliknięcie](#)), ignorując oceny w gwiazdkach.

## 2. Przetwarzanie:

- **Filtrowanie:** Usunięto użytkowników i przedmioty z mniej niż [5 interakcjami](#), aby zapewnić minimalną jakość sygnału.
- **Strategia doboru:** Zastosowano strategię [Sparse \(Losową\)](#). Wybrano losową próbę użytkowników, aby zachować naturalną rzadkość danych i uniknąć sztucznego zagęszczenia (tzw. biasu "[power users](#)").

## 3. Statystyki Podzbioru:

- **Liczba użytkowników:** 20 000 (połowa wszystkich użytkowników z Amazon-Book).
- **Liczba przedmiotów:** ~90000.
- **Liczba interakcji:** ~900000.
- **Podział (Data Split):** 80% Trening / 10% Walidacja / 10% Test.

**Krytyczne pytanie**

**Czy LightGCN uzyskał lepsze rezultaty  
względem NGCF?**

# Dowód – porównanie wyników


W bezpośrednim porównaniu na tych samych zbiorach danych i przy tej samej liczbie warstw, LightGCN osiąga znacznie lepsze wyniki na wielu płaszczyznach.

**NGCF vs LightGCN**


Kategoria	NGCF	LightGCN	Względna poprawa
Czas trenowania sieci	~150min	<b>~75min</b>	<b>-50%</b>
Recall@20	0.0361	<b>0.0431</b>	<b>+19,3%</b>

# Dowód – porównanie wyników cd

Porównanie skuteczności (Recall@20) na zbiorze Amazon-Book




LightGCN




GNCF

# Dowód – porównanie wyników cd


**Porównanie wykresu funkcji straty (BPR) na zbiorze Amazon-Book**



**LightGCN**



**GNCF**



**Prosty model**



**Skomplikowany  
model**

# Wierne odtworzenie publikacji naukowej

Niestety, jednym z największych problemów współczesnej nauki o danych jest "Kryzys Reprodukowalności" (The Reproducibility Crisis).

## "Piekło Zależności":

Różne wersje bibliotek (np. [TensorFlow 2.x vs 1.x](#), [PyTorch](#)) mają inne domyślne ustawienia i implementacje matematyczne.

## Ukryte Detale ("Secret Sauce"):

Publikacje naukowe często pomijają szczegóły inżynierskie, t.j. dokładna metoda [preprocessingu danych](#), sposób losowania negatywów czy strategia tworzenia batchy.

## Loteria Inicjalizacji:

[Losowy dobór wag początkowych](#) ma ogromny wpływ na to, czy model utknie w słabym minimum lokalnym, czy osiągnie świetny wynik.

## Niespójność Metryk:

Różne definicje tych samych miar (np. różne warianty wzoru na NDCG) lub [stosowanie uproszczonej ewaluacji](#).

# **Dziękujemy za uwagę**

Michał Tomaszewski  
Damian Tomczyk  
Szymon Wierzchoś